Technická zpráva

1 Zadání

Část A – Obrazová korelace. Úkolem bylo implementovat algoritmus pro vyhledávání vzorů v Müllerově mapě Čech na základě obrazové korelace.

Část B – Obrazová segmentace. Úkolem bylo nad obrazem Topografické mapy ČSSR v měřítku 1 : 25 000 implementovat algoritmus obrazové segmentace pomocí metody k-means. Výsledkem měla být extrahovaná plocha lesů očištěná o vrstevnice a další překryvnou kresbu, s odečtenými lesními průseky a zachovanými otvory většími než 50 pixelů.

2 Základní informace

Zpracovatelé: *Maiia Liashenko, Martin Ludvík*
Datum zpracování: *9.11.2026*
Pracovní prostředí: MATLAB
Použité AI nástroje: ChatGPT, Claude.ai

3 Postup řešení

3.1 Část A – Obrazová korelace

Nejprve byl načten rastr Müllerovy mapy Čech. Pro následné vyhledávání vzorů byla vypočtena složka L barevného prostoru HSL z barevných složek RGB.

Vyhledávací vzor obce s kostelem vznikl z pěti výřezů zvolených uživatelem. Tyto výřezy byly převzorkovány na společnou velikost určenou mediány jejich výšek a šířek a následně zprůměrovány.

Normalizovaná obrazová korelace mezi zprůměrovaným vzorem a mapou byla provedena pomocí funkce `normxcorr2`. Práh korelace byl nastaven na 0,61. Byla vybrána lokální maxima dosahující alespoň této hodnoty. Zohledněny byly pouze polohy, ve kterých celý vzor ležel uvnitř rastru, nad nímž se korelace prováděla.

Pro odstranění vícenásobných detekcí byly nalezené polohy seřazeny sestupně podle hodnoty korelace. V okolí každé ponechané polohy byly odstraněny slabší detekce, jejichž vzdálenost v obou souřadnicových směrech byla menší než polovina příslušného rozměru vzoru.

Souřadnice maximálních hodnot korelace byly přepočteny na pixelové souřadnice levých horních rohů a středů nalezených výřezů. Výsledky byly uloženy do příslušného souboru spolu s identifikátory a hodnotami korelace.

3.2 Část B – Obrazová segmentace

Na začátku byla načtena topografická mapa ve formátu rastru, který byl vyhlazen Gaussovým filtrem se směrodatnou odchylkou 0,7 pixelu pro omezení drobného barevného kolísání a obrazového šumu. Vyhlazený obraz byl následně převeden z barevného prostoru RGB do barevného prostoru CIELAB, kde L^* vyjadřuje světlost, a^* vyjadřuje zeleno-červenou barevnou polohu a b^* vyjadřuje modro-žlutou barevnou polohu. Lesní plochy mají především zelené odstíny, proto byla složka a^* využita při automatickém přiřazení významu vytvořeným třídám.

K barevným složkám byl přidán příznak popisující proměnlivost světlosti. Pro každý pixel bylo vybráno okolí 5×5 pixelů, obsahující dohromady 25 hodnot světlosti L^*, z nichž byla pomocí

funkce `stdfilt` vypočtena směrodatná odchylka. V místech, kde se střídají světlé a tmavé pixely, je hodnota odchylky větší. Následně byl výsledek vynásoben vahou 0,5 pro omezení jeho vlivu při segmentaci. Každý pixel byl reprezentován následujícími příznaky:

$$\mathbf{f} = [L^*,\, a^*,\, b^*,\, 0{,}5\, s_L],$$

kde s_L označuje lokální směrodatnou odchylku světlosti.

Následně proběhla segmentace metodou k-means pomocí funkce `imsegkmeans`, která rozdělila obraz do osmi tříd podle podobnosti příznaků jednotlivých pixelů. Příkazem `rng(1)` byl nastaven generátor náhodných čísel, aby bylo možné při stejném vstupu a nastavení výpočet opakovat se stejným výsledkem. Byly vyzkoušeny tři různé inicializace a vybráno nejlepší rozdělení podle kritéria k-means. Automatická normalizace vstupních příznaků byla vypnuta, aby nedošlo k automatickému sjednocení měřítek čtyř vstupních příznaků.

Třídy vytvořené metodou k-means neměly předem určený význam, proto byla jejich interpretace provedena automaticky podle barevných souřadnic jejich středů.

Nejprve byla vybrána referenční třída podkladu mapy. Pro každou třídu byla vypočtena chromatičnost neboli míra barevnosti:

$$C^* = \sqrt{(a^*)^2 + (b^*)^2}.$$

Mezi třídami s hodnotou $C^* < 20$ byla vybrána třída s nejvyšší světlostí L^*. Pokud žádná třída tuto podmínku nesplnila, byla vybrána nejsvětlejší třída ze všech osmi tříd. Ostatní třídy byly posuzovány vůči tomuto referenčnímu podkladu. Z výsledného přiřazení byly vytvořeny binární masky lesa, mapové kresby a podkladu.

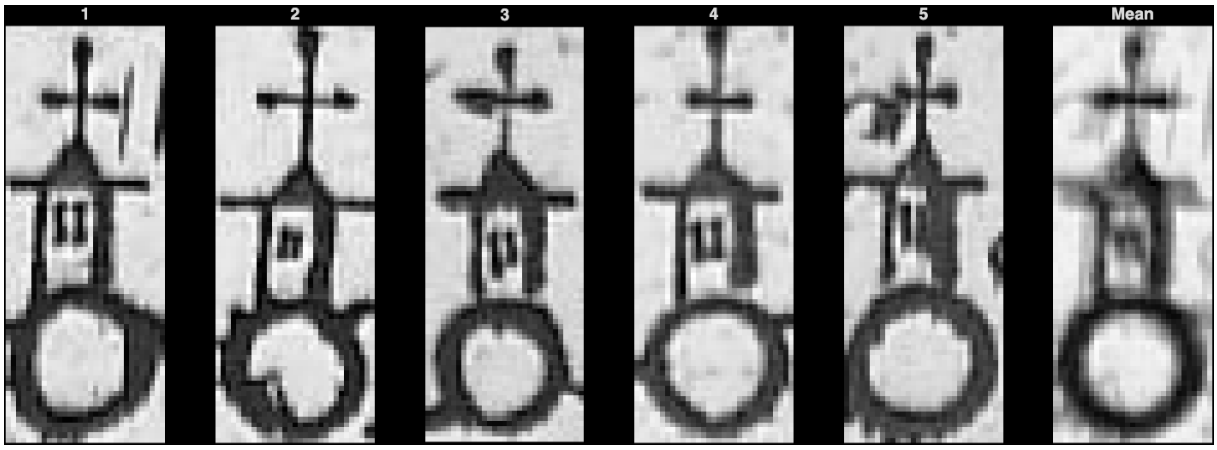
Maska mapové kresby byla rozšířena dilatací s poloměrem jednoho pixelu, aby zahrnovala také okolí linií. Následně byly v pohyblivém okně 15×15 pixelů vypočteny podíl pixelů nezakrytých rozšířenou maskou kresby a podíl pixelů, které patřily do lesa a nebyly zakryty kresbou. Pixel byl zařazen do rekonstruované lesní masky, pokud lesní pixely tvořily více než 50 % nezakrytých pixelů. Současně musely nezakryté pixely tvořit více než 10 % celého okna.

Rekonstruovaná maska následně prošla morfologickými úpravami pro propojení blízkých částí lesa a zacelení úzkých mezer. Pro odečtení lesních průseků byla použita upravená maska tříd přiřazených podkladu mapy. Ta byla od lesní masky odečtena. Pomocí funkce `imfill` byly následně určeny uzavřené otvory, z nichž byly vyplněny pouze otvory o velikosti nejvýše 50 pixelů.

Z výsledné binární masky byly získány indexy všech pixelů reprezentujících lesní plochu. Pole souřadnic a binární maska byly uloženy do souboru `forest_pixels.mat`.

4 Výsledky

4.1 Část A – Obrazová korelace



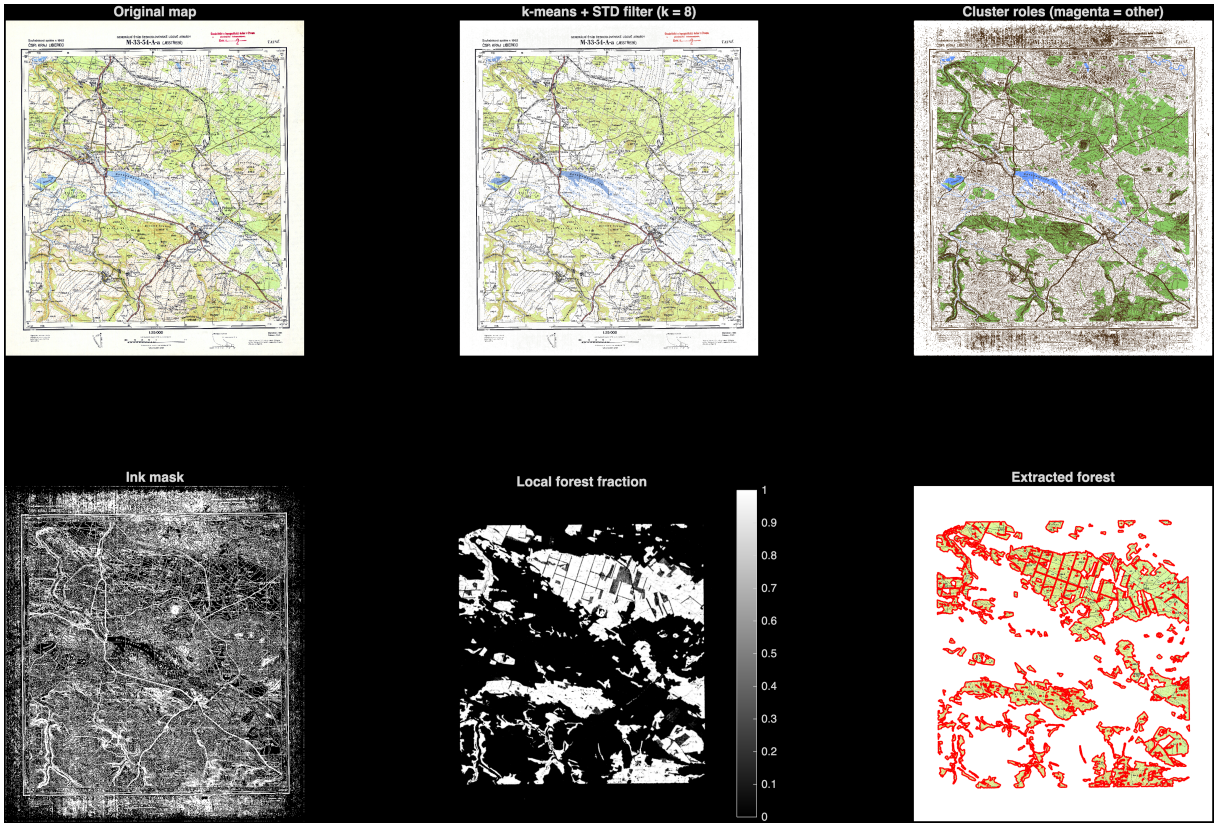
Obrázek 1: Pět vybraných vzorů a výsledný průměrný vzor.

Po odstranění vícenásobných detekcí bylo získáno 39 nalezených poloh. Jejich rozmístění v mapě je znázorněno na obrázku 2. Červené značky jsou doplněny identifikačními čísly a hodnotami korelace. Zobrazené hodnoty se pohybují od 0,61 do 0,85. Nejvyšší korelace dosáhl objekt s identifikátorem 1. Správnost a úplnost detekcí ale nelze určit pouze z hodnot korelace, je potřeba také provést kontrolu vůči původní mapě.



Obrázek 2: Výsledné detekce značek obcí s kostelem.

4.2 Část B – Obrazová segmentace



Obrázek 3: Původní mapa, segmentace do osmi tříd se STD příznakem, význam tříd, maska kresby, lokální podíl lesa a výsledná extrakce.



Obrázek 4: Výsledná lesní maska.

Výsledná maska na obrázku 4 zachycuje rozsáhlé lesní celky i menší oddělené lesní plochy. Uvnitř lesa zůstávají nezalesněné prostory a drobné mezery či nepravidelnosti hranic.